

Predicción de Accesibilidad a la Salud con Machine Learning

Rocío Wegman

1- Introducción

El acceso a la salud y la identificación de sus barreras constituyen un fenómeno complejo y multidimensional, donde intervienen dimensiones sociales, económicas, territoriales y simbólicas. Por lo mismo, su estudio puede ser encarado desde las metodologías, abordajes y escalas más variadas. En este trabajo, exploramos en particular los determinantes del acceso en términos del tiempo que toma llegar a pie al hospital y centro de salud más cercano en los aglomerados urbanos. Esta concepción de accesibilidad comparte la perspectiva de la Organización Mundial de la Salud, entendida como los aspectos estructurales del sistema de salud que facilitan el encuentro entre población y servicios, en términos de localización, tiempo de desplazamiento y facilidad de aproximación (World Health Organization, 2017, 2021). Con esta definición ponemos el foco en la posibilidad física de llegar a un centro de atención por cuanto constituye una condición mínima e indispensable para su acceso.

Con todo, la relevancia de pensar la accesibilidad no solo viene dada por la posibilidad de identificar cuán cerca o lejos están los servicios de salud, sino que se justifica en el intento por comprender cómo el territorio participa en la producción de desigualdades sanitarias. Estudiar la accesibilidad geográfica puede resultar clave, entonces, para identificar patrones de exclusión estructural y visibilizar brechas territoriales en el despliegue del sistema de salud.

Para conocer cuáles son sus determinantes, en este trabajo exploratorio nos proponemos entrenar, comparar e interpretar dos modelos de Machine Learning de Aprendizaje supervisado (Random Forest y XGBoost). El entrenamiento se realizará con las siguientes bases de datos disponibles: Censo Nacional de Población y Vivienda (2010), Encuesta Permanente de Hogares, una base de datos sobre vulnerabilidad sanitaria del 2018 (poblaciones.org) y de establecimientos productivos proviene de los registros administrativos del Sistema Integrado Previsional Argentino (SIPA) y de la Administración Federal de Ingresos Públicos (2023). El objetivo será construir un mapa de accesibilidad en Argentina con la mayor granularidad e identificar sus principales determinantes, especialmente en los aglomerados urbanos.

2- Pre-procesamiento

En este apartado desarrollaremos el conjunto de decisiones que involucra la transformación de bases de datos y variables con las que trabajamos para entrenar y predecir la accesibilidad a la salud.

2.1 Dimensión urbana

Una primera consideración radica en tomar la accesibilidad a la salud en las grandes urbes: decidimos restringir el análisis exclusivamente a los radios ubicados dentro de aglomerados urbanos, ya que estos concentran la mayor parte de la población. Según el CENSO de 2010, el 90 % de la población argentina residía en zonas urbanas. En este sentido, tomamos como referencia la Encuesta Permanente de Hogares para vincular los radios censales pertenecientes a cada aglomerado, lo que resulta clave para distinguir las zonas urbanas del resto del territorio.


2.2 Construcción variable target

La segunda consideración estructural a nuestro trabajo involucra tomar la accesibilidad a partir de dos de tres efectores: los centros de salud y hospitales. Esta decisión se encuadra en la naturaleza de la base de datos de vulnerabilidad sanitaria¹. Así, optamos por excluir de la construcción de la variable target a las “postas” ya que, como mencionan en su trabajo Vázquez Brust, Olego y Rosati (2018), existe una gran cantidad de regiones con tiempos de viaje notablemente elevado, en contraste con hospitales y centros de salud. Según los autores, esta característica puede deberse a diferentes políticas provinciales en la asignación de postas sanitarias y/o a errores de cobertura en los datos analizados, es decir, que haya zonas en las que la omisión de postas sanitarias sea muy elevada. Y además, esa variable contaba con una cantidad mucho mayor de NA que las anteriores (2790).


En este sentido, decidimos conservar sólo aquellas observaciones que tienen valores no faltantes (es decir, no NA) en ambas variables: tpo_hospital y tpo_ctro_salud. Tomamos esa decisión ya que para ambas variables los casos faltantes eran pocos (menos de 100) y optamos por garantizar que se trabaje solo con observaciones completas.

En la exploración de estas variables (tpo_hospital y tpo_ctro_salud) identificamos –después de haber seleccionado solo los radios urbanos– una concentración de outliers dentro de los valores altos, que no solo eran extremos sino también poco realistas. Para tpo_hospital el valor mínimo era 0.7 minutos, la mediana 21.9, la media 30,7 y el valor máximo 2087 (casi un día y medio). Para tpo_ctro_salud el valor mínimo era 0,69 minutos, la mediana 9,25, la media 12,5 y el valor máximo 762.5 (es decir, 12 horas).

¹ El tiempo de traslado a los efectores de salud se calcula a partir de tomar al azar cinco coordenadas dentro del radio, se extrae la distancia/tiempo al efector de salud más cercano de dichas coordenadas, y se promedian las 5 distancias/tiempos para el valor final del tiempo. (Vázquez Brust, A., Olego, T., & Rosati, G; 2018).




En este marco decidimos filtrar los valores extremos quedándonos con el 99.5% de los casos. De este modo, para el caso de `tpo_hospital`, su mediana ahora es de 21.6 minutos, su media: 28 y máximo es de 174 minutos y para `tpo_ctro_salud` mediana 9.1, media: 11.4 y máximo 76.



En este marco, con el objetivo de sintetizar la información contenida en estas dos variables, aplicamos el Análisis de Componentes Principales (PCA), una técnica estadística orientada a la reducción de la dimensionalidad de variables cuantitativas cuando nos enfrentamos a un conjunto de variables correlacionadas. Se trata de una técnica propia del aprendizaje no supervisado ya que no involucra una variable objetivo específica, sino que explora la estructura de las variables independientes para identificar patrones o relaciones subyacentes en los datos. Para eso dividimos el dataset en dos partes: una para entrenar el modelo y otra para probarlo, usando `initial_split()`. El análisis de componentes principales (PCA) se hizo solo con los datos de entrenamiento y, antes de calcularlo, se normalizaron las variables para que todas estuvieran en la misma escala. Una vez calculado el modelo, se aplicó esa misma

transformación al dataset completo, generando dos nuevas variables (PC1 y PC2) que resumen la información de los tiempos de acceso.



La proporción de varianza explicada (PVE) muestra cuánta información se conserva al usar solo algunos componentes. En el anterior gráfico, podemos ver que PC1 concentra el 60 % de la varianza total, mientras que PC2 explica alrededor del 40 % restante. Esto indica que gran parte de la información contenida en ambas variables puede ser resumida en una única dimensión (PC1), que funciona como un indicador compuesto del tiempo de acceso a centros de salud.

2.3 Variables predictoras

El conjunto de variables predictoras abarca en el uso de tres tipos de bases de datos: el Censo de Población y Vivienda del año 2010; establecimientos productivos y una variable creada a partir de las distancias al centroide del radio.

2.3.1 Variables de infraestructura y régimen de tenencia (Censo 2010)

El dataset del Censo Nacional de Población y Vivienda del año 2010 contiene información sobre las características habitacionales de los hogares, como los pisos, el revestimiento, la cubierta exterior del techo, las formas de acceder al agua en la vivienda, la procedencia del agua, la disponibilidad de baño / letrina, la disponibilidad de botón, cadena, mochila para limpieza del inodoro y el desagüe del inodoro. Además, incluye información sobre los hogares con y sin NBI (necesidades básicas insatisfechas) y el régimen de tenencia de la propiedad de la vivienda. Las variables contienen la proporción de hogares dentro de cada radio censal que son clasificados en cada categoría, por ese motivo la unidad de análisis y el nivel de desagregación geográfica son los radios censales. Consideramos que estas variables pueden ser importantes para predecir la accesibilidad a la salud ya que aportan información sobre las condiciones de vida, el grado de urbanización, la conectividad y la presencia estatal que pueden afectar la presencia o ausencia de efectores de salud cercanos.

2.3.2 Establecimientos productivos

Luego, utilizamos el dataset sobre establecimientos productivos, que proviene de los registros administrativos del Sistema Integrado Previsional Argentino (SIPA) y de la Administración Federal de Ingresos Públicos (AFIP). Su unidad básica son los establecimientos y contiene información sobre la cantidad de trabajadores registrados por establecimiento, el sector de actividad al que pertenecen, la proporción de trabajadoras mujeres, el nivel de exportaciones (agrupado en quintiles) y su jurisdicción. La información releva la situación del empleo asalariado formal en empresas durante el período comprendido entre enero y diciembre de 2021 y 2022. Cabría esperar que el grado de diversidad económica de una región pueda ser un factor influyente para predecir la accesibilidad a la salud dado que el entorno socioeconómico de la zona, incluyendo su estructura productiva y acceso formal al empleo, conforma un contexto que influye en la disponibilidad, infraestructura y conectividad del sistema de salud. En cuanto a su nivel de desagregación geográfica, el dataset incluye las coordenadas (latitud y longitud) de cada establecimiento, así como los códigos de provincia y departamento. Dado que el nivel de desagregación de los otros dataset era por radio censal, en este caso realizamos un join espacial utilizando las coordenadas. Para unir los establecimientos productivos con los radios censales, primero se transformaron las coordenadas de latitud y longitud de los establecimientos en un objeto espacial (sf) utilizando `st_as_sf()`. Esto permitió tratarlos como puntos georreferenciados. Luego, se utilizó la función `st_join()` con el argumento `join = st_within`, lo que significa que cada establecimiento fue asignado al radio censal dentro del cual se encuentra ubicado espacialmente. La función `st_within` verifica si la geometría de un punto (el establecimiento) está completamente contenida dentro de la geometría de un polígono (el radio censal), permitiendo así unir atributos del radio al punto correspondiente.


Sumado a eso, transformamos las variables de este dataset para poder agregarlas y analizarlas a nivel de radio censal. Dado que la unidad mínima del dataset son los establecimientos y podría haber más de un establecimiento por radio, filtramos los establecimientos que pudieron ser georreferenciados dentro de un radio, y luego los agrupamos por dicha unidad territorial. Para cada radio, se calcula la cantidad total de establecimientos (la suma), y el promedio de la proporción de mujeres empleadas. También se calcula el quintil modal, es decir, el valor más frecuente del nivel socioeconómico de los establecimientos del radio, y el CLAE6 modal, que representa la actividad económica predominante en términos de frecuencia. Por otra parte, la variable empleo originalmente tiene valores en formato de rangos de personas empleadas, como “10-49”. Para poder trabajar con esta información le asignamos a cada categoría un valor representativo del rango: por ejemplo, al rango “10-49” se le asigna 30 (la mitad). Luego, se suman estos valores para estimar el total de empleo en cada radio. Para los valores faltantes asignamos 0 a las variables cuantitativas como cantidad de establecimientos y empleo total, y NA a las variables categóricas o proporciones, para evitar introducir datos artificiales donde no hubo establecimientos.

2.3.3 Incorporación de una nueva variable espacial: distancia al centroide urbano

Para enriquecer la capacidad predictiva del modelo y capturar desigualdades espaciales dentro de los aglomerados urbanos, incorporamos una nueva variable: la distancia entre cada radio censal y el centroide geométrico del aglomerado al que pertenece. Esta medida fue calculada exclusivamente para radios ubicados en aglomerados urbanos identificados en el dataset de la EPH (env_eph), y se basa en el supuesto de que la localización relativa dentro de una ciudad —más o menos central— podría condicionar el acceso efectivo a los servicios de salud.

El procedimiento técnico consistió en reproyectar las geometrías al sistema métrico (EPSG:3857), luego agrupar los radios por aglomerado y calcular el centroide geográfico de cada uno mediante `st_centroid(st_union())`. Posteriormente, se midió la distancia euclidiana entre cada radio y el centroide correspondiente (en kilómetros), lo cual resultó en una variable continua denominada `distancia_centroide_km`. Finalmente, esta variable fue transformada en escala logarítmica (`log_distancia_centroide`) para reducir el efecto de los valores extremos, especialmente en aglomerados extensos como el Gran Buenos Aires.

Los histogramas presentados a continuación muestran que la distribución original de distancias presenta una asimetría positiva con alta dispersión, mientras que su transformación logarítmica reduce significativamente ese sesgo, concentrando los valores en una escala más homogénea y adecuada para su inclusión en el entrenamiento de los modelos.




Esta variable fue incorporada tanto en los modelos supervisados (Random Forest y XGBoost) bajo la hipótesis de que los radios más periféricos podrían enfrentar mayores tiempos de acceso a los efectores de salud por su localización marginal respecto del nodo urbano central. En este sentido, se pensó que, para mejorar el entrenamiento —y predictibilidad del modelo— la variable creada se la podría hacer interactuar con la variable aglomerado.

3. Construcción de mapas desagregados de la accesibilidad a la salud

Nuestro primer objetivo —mapear la accesibilidad a la salud en Argentina— puede ser abordado a partir de graficar la primera componente principal que obtuvimos al reducir la dimensionalidad en el acceso al tiempo a hospitales y centros de salud. En dicho PCA,

obtuvimos las cargas factoriales (o loadings) que indican cuánto aporta cada variable original a cada componente. Los resultados del análisis de componentes principales (PCA) muestran que ambas variables aportan por igual a las dos primeras componentes principales, con cargas de aproximadamente +0.71. El peso simétrico en la construcción de los nuevos ejes resulta un patrón esperable para variables altamente correlacionadas.



El análisis de las cargas factoriales nos permite ver la dirección en la que influyen. Esto es central para interpretar correctamente el mapa de accesibilidad. Valores altos de PC1 (amarillo) indican mayores tiempos, por tanto menor accesibilidad, al contrario, los colores violetas indican mejor accesibilidad.



El gráfico anterior toma grupos de 9 aglomerados con “importancia” decreciente, es decir, de aglomerados más grandes a más chicos. Los otros gráficos —ordenados con el criterio mencionado— se pueden consultar en el Anexo I. El hecho de que algunas zonas pequeñas tengan PC1 constante (ver últimos 3 aglomerados del Anexo) sugieren radios con un solo efector de salud en el aglomerado. La clave central de contrastar a todos los aglomerados reside en cierta figura constante que indica la organización socio-territorial de “centro-periferia” a partir del modo en que se distribuyen los efectores de salud, y con ellos, las desigualdades territoriales en el acceso.

4. Procesamiento: entrenamiento de modelos de Machine Learning

En este apartado entrenamos dos modelos de regresión supervisada con el objetivo de predecir la variable PC1 —nuestro primer componente principal, derivado de los tiempos de acceso a centros de salud— e identificar sus principales determinantes. Para ello, seleccionamos dos algoritmos con enfoques distintos: Random Forest, basado en el promedio de árboles entrenados en paralelo (*bagging*), y XGBoost, basado en el entrenamiento secuencial y acumulativo de árboles mediante *boosting*. A continuación, se detallan las características técnicas y procedimientos de entrenamiento aplicados a cada modelo.

4.1 Random forest

Random Forest es un algoritmo de *ensemble learning* que combina múltiples árboles de decisión para mejorar la precisión predictiva mediante la reducción de la varianza. Los árboles de decisión son modelos supervisados que segmentan el espacio de predictores en regiones cada vez más homogéneas respecto de la variable objetivo, utilizando como criterio la disminución de varianza (en el caso de regresión). Sin embargo, cuando se utilizan individualmente, estos modelos tienden a sobreajustarse (*overfitting*), ya que se adaptan excesivamente a los datos del conjunto de entrenamiento. Además, su construcción responde a una lógica *greedy*, en la que cada división se elige de manera local, sin considerar el efecto global sobre el árbol completo, lo que puede derivar en soluciones subóptimas.

La fortaleza de Random Forest radica en dos mecanismos clave: primero, cada árbol se entrena sobre una muestra diferente obtenida mediante *bootstrap* (remuestreo con reemplazo), lo que introduce variabilidad entre árboles; segundo, en cada división, el algoritmo selecciona aleatoriamente un subconjunto de predictores en lugar de considerar todos, lo que evita la repetición de patrones. Esta doble aleatorización permite generar árboles diversos cuyas predicciones, al promediarse, reducen la varianza y mitigan el sobreajuste.

Para su implementación, se particionó el conjunto de datos con `initial_split()` y se definió una grilla de búsqueda de hiperparámetros con tres componentes: 1. cantidad de árboles (`trees`), 2. número de predictores por división (`mtry`) y 3. número mínimo de observaciones por nodo terminal (`min_n`). Esta grilla fue evaluada con validación cruzada (`vfold_cv()`, $k = 5$), y se utilizó `tune_grid()` para explorar todas las combinaciones posibles. El mejor conjunto de hiperparámetros fue seleccionado con `select_best()` en base al menor RMSE. El modelo final, entrenado con `finalize_model()`, utilizó: `trees = 500`, `mtry = 10` y `min_n = 20`. Finalmente, el

modelo se entrenó sobre el conjunto de entrenamiento (80% de los datos) y se evaluó sobre el conjunto de prueba (20%).

4.2 XGBoost

Extreme Gradient Boosting (XGBoost) es una implementación optimizada del algoritmo de *boosting*, que construye modelos secuenciales donde cada nuevo árbol intenta corregir los errores cometidos por los anteriores. A diferencia de métodos como Random Forest —donde los árboles son entrenados de forma independiente y luego combinados—, el boosting acumula modelos débiles (*weak learners*) de forma iterativa, generando una predicción final que resulta de la suma ponderada de sus contribuciones. Cada iteración entrena un nuevo árbol sobre los residuos del modelo anterior, mejorando así progresivamente la precisión.

XGBoost trabaja con funciones de pérdida diferenciables, como el error cuadrático medio en regresión, y actualiza las predicciones mediante una tasa de aprendizaje (`learn_rate`, γ), que controla cuánto aporta cada nuevo árbol a la predicción final. Esta tasa permite regular la influencia de cada iteración, evitando el sobreajuste y estabilizando el aprendizaje. Este enfoque se destaca por su eficiencia computacional, su capacidad para modelar relaciones complejas y su robustez frente a valores atípicos.

En este caso, se tuneó automáticamente un conjunto de hiperparámetros: (1) número de árboles (`trees`), (2) profundidad máxima (`tree_depth`), (3) número mínimo de observaciones por nodo (`min_n`), (4) ganancia mínima para dividir (`loss_reduction`), (5) número de predictores evaluados por división (`mtry`) y (6) tasa de aprendizaje (`learn_rate`), esta última restringida al rango 0.01–0.3 para suavizar el proceso de ajuste. La grilla de combinaciones fue generada con `grid_space_filling()` (25 combinaciones²), que busca diversidad sin redundancia.

Al igual que en Random Forest, se aplicó validación cruzada y se evaluaron métricas de regresión (RMSE, MAE, MAPE y R^2). Se seleccionó el mejor modelo con `select_best()` y se construyó el modelo final con `finalize_model()`. Luego de su entrenamiento sobre el conjunto de entrenamiento, se generaron predicciones sobre el test y se utilizó la función `vip()` para analizar la importancia relativa de las variables predictoras en la performance del modelo.

5. Análisis de Resultados

Uno de los desafíos más importantes al trabajar con modelos de machine learning es el balance entre la interpretabilidad y la precisión de las predicciones. A medida que avanzamos hacia modelos más complejos, como los random forest y los modelos de boosting, ganamos


² Reconocemos que este valor es muy bajo; al contar con 26.000 observaciones (radios censales) y 6 hiperparámetros a tunear, una grilla de 25 combinaciones resulta notablemente limitada. Un mínimo razonable hubiera sido 50 aunque sería recomendable probar de 100 a 200 para alcanzar una cobertura más representativa del espacio de búsqueda y mejorar el ajuste del modelo. Esto mismo sucedió también para el “mtry” en Random Forest.

en capacidad predictiva, pero podemos perder cierta claridad sobre cómo cada variable influye en el resultado final.

Para comprender este balance, comenzaremos presentando un boxplot del primer componente principal (PC1) para contextualizar el rango de nuestra variable objetivo, lo que nos permitirá entender mejor el significado de las métricas para evaluar el modelo.

5.1 Rango de la variable target

Como se observa en el siguiente boxplot, el primer componente principal (PC1) –utilizado como variable objetivo en los modelos supervisados– presenta una distribución fuertemente asimétrica. Si bien su rango completo se extiende entre -1,6 y 9,4, la mayor parte de las observaciones se concentra en un intervalo mucho más reducido, aproximadamente entre -0,2 y 0,2. Esta concentración se refleja en un rango intercuartílico estrecho y en la presencia de numerosos valores atípicos positivos.




La existencia de este núcleo denso en torno a la mediana hace que los errores de predicción, medidos por métricas como el RMSE, deban interpretarse no solo en relación al rango total de la variable, sino también respecto a la variabilidad efectiva del conjunto de datos. Un mismo valor absoluto de error puede tener implicancias distintas según se ubique dentro o fuera del rango en que se concentra la mayoría de los casos.

Teniendo en cuenta esta estructura de la variable objetivo, en el siguiente apartado se comparan los resultados obtenidos por los modelos de Random Forest y Boosting, a partir de sus métricas de error en los conjuntos de entrenamiento y testeo.

5.2 Evaluación de los modelos: RMSE

Habiendo presentado el marco en el que se debe interpretar la evaluación del modelo veamos el siguiente gráfico de barras que permite comparar el desempeño de los modelos Random Forest y XGBoost.




Se utilizaron dos métricas de evaluación: RMSE (raíz del error cuadrático medio) y MAE (error absoluto medio). Como es habitual en problemas de aprendizaje supervisado, los errores fueron menores en el conjunto de entrenamiento que en el de testeo, ya que el primero se emplea para ajustar el modelo, mientras que el segundo permite evaluar su capacidad de generalización sobre datos no vistos. La diferencia entre RMSE y MAE —dado que el primero penaliza más fuertemente los errores grandes— sugiere la presencia de predicciones con desvíos amplios en ambos modelos.

Para la comparación final se priorizó el RMSE, ya que incluso luego de excluir valores atípicos, resultaba importante contar con una métrica sensible a los errores de mayor magnitud. Al elevar al cuadrado las diferencias entre valores observados y predichos, el RMSE permite detectar con mayor claridad los casos donde el modelo falla significativamente. En este marco, Random Forest mostró un mejor desempeño, tanto en el ajuste sobre los datos de entrenamiento como en su capacidad de generalizar sobre el conjunto de prueba.

Dado que el RMSE penaliza con mayor intensidad los errores grandes, la diferencia observada entre modelos sugiere que Boosting incurrió con mayor frecuencia en predicciones con desvíos amplios, especialmente en los extremos del rango. En el conjunto de testeo, Random Forest obtuvo un RMSE cercano a 0,75, mientras que Boosting superó los 0,85. Si se considera que la variable PC1 varía aproximadamente entre -1,6 y 9,4 (11 unidades en total), estos valores representan entre un 6,8 % y un 7,7 % del rango completo, lo que permite considerarlos aceptables en términos relativos. No obstante, dado que más del 50 % de los valores de PC1 se concentran en un intervalo intercuartílico de solo 0,4 unidades, incluso diferencias de unas décimas en el RMSE pueden tener un impacto considerable sobre la calidad del ajuste en la zona central de la distribución. En este sentido, sería crucial —agregamos— trabajar correctamente las escalas de la variable PC1 para reducir el rango y ofrecer al modelo una variable más acotada para predecir.

5.3 Distribución y magnitud de los errores de predicción

Además del análisis de métricas globales como el RMSE, resulta fundamental observar cómo se distribuyen los errores individuales de predicción para evaluar la estabilidad y robustez de cada modelo. El siguiente histograma superpuesto muestra la distribución de los errores de predicción (residuos) para los modelos de Random Forest y Boosting en el conjunto de testeo.



Ambos modelos presentan un patrón centrado en cero, lo cual indica que, en promedio, no tienden a sobrestimar ni subestimar sistemáticamente los valores de la variable objetivo. Sin embargo, el Random Forest exhibe una mayor concentración de errores cercanos a cero, lo que se traduce en una forma más alta y angosta de la distribución. Esto sugiere una mayor precisión global en las predicciones y una menor dispersión de los errores. Por otro lado, el modelo de Boosting muestra una distribución más extendida, con mayor frecuencia de errores moderados y extremos, especialmente hacia los valores negativos. Esta diferencia en la dispersión está en línea con lo observado en el RMSE: el Boosting incurre con mayor frecuencia en errores grandes, lo que incrementa su valor cuadrático medio de error.


En ambos modelos —Random Forest y XGBoost (ver Anexo 2)—, a medida que aumentan los valores predichos de PC1 —es decir, en los casos de mayor inaccesibilidad estimada— los errores también se amplifican, mostrando una mayor dispersión. Esto sugiere que ambos modelos predicen con mayor precisión las situaciones de accesibilidad media o buena, pero presentan mayor variabilidad en los extremos. Esta tendencia puede deberse a una menor representación de casos críticos en el entrenamiento y a la ausencia de variables que capten adecuadamente sus condiciones.

5.4 Importancia de las variables


La importancia de las variables fue evaluada mediante Importancia de permutación (VIP), que refleja el impacto de cada variable sobre el RMSE al permutar su valor. Dado que uno de los ejes centrales del trabajo es identificar los principales determinantes del acceso sanitario,

VIP permite obtener una medida global y comparativa de la contribución de cada variable al modelo de predicción.

Para Random Forest, el siguiente gráfico muestra que algunas de las variables con mayor importancia relativa son `log_distancia_centroide`, `aglomerado_Gran.Buenos.Aires` y su interacción con la distancia. Esta configuración sugiere que las variables de localización geográfica tienen un peso relevante en la predicción del índice de accesibilidad a la salud, y que este patrón se manifiesta especialmente en el Gran Buenos Aires. Además de las variables espaciales, se destacan componentes de infraestructura básica como `desague_red_cloaca` y `agua_de_red`, lo que sugiere que las condiciones mínimas de urbanización continúan funcionando como buenos proxies del entorno urbano y del nivel de integración territorial. También aparecen con cierto peso variables como la tenencia de la vivienda y el número de establecimientos productivos, lo que permite vincular la accesibilidad con el tejido económico local y las condiciones materiales de los hogares.



En el modelo XGBoost, las variables más importantes fueron, en primer lugar, `log_distancia_centroide`, junto con varias interacciones entre esta variable y aglomerados específicos como La Plata, Mendoza, Córdoba, Buenos Aires y Mar del Plata. Esto indica que la ubicación geográfica dentro del aglomerado urbano, en particular la proximidad al centro, es un factor clave para explicar los valores del índice PC1. Entre las variables no espaciales se destacaron `agua_de_red` —que ocupó el primer lugar en importancia general— y `regimen_tenencia_propietario`. Ambas remiten a condiciones de infraestructura básica y consolidación habitacional, lo que indica que estos factores también contribuyen de forma significativa a explicar las desigualdades captadas por el componente principal.



Si bien ambos modelos coinciden en destacar la distancia al centroide como una de las variables más relevantes, se observan algunas diferencias en el orden y tipo de variables priorizadas. En Random Forest, las variables de infraestructura básica como desague_red_cloaca y agua_de_red también ocupan posiciones destacadas, aunque aparecen por detrás de los factores espaciales; a diferencia de XGBoost, que pondera fuertemente las interacciones específicas entre distancia y aglomerado, Random Forest atribuye mayor importancia al efecto general de la localización y al contexto territorial amplio, como la pertenencia al aglomerado Gran Buenos Aires.

6. Conclusiones

La accesibilidad a la salud fue modelada a partir del tiempo estimado de traslado a pie a hospitales y centros de salud, sintetizado mediante un componente principal (PC1). Este índice permitió capturar, de forma continua y comparativa, las diferencias territoriales en la posibilidad física de alcanzar un efector sanitario. Los resultados obtenidos muestran que, además de las condiciones habitacionales y productivas, la centralidad geográfica del radio censal —es decir, su cercanía al centro del aglomerado urbano— se destaca como un factor clave en la predicción del modelo. Esta evidencia refuerza la hipótesis de que la distribución de los efectores de salud reproduce una lógica centro-periferia, tanto al interior de cada aglomerado como en relación al “centro” del país, representado por el Gran Buenos Aires.

Sin embargo, estas conclusiones deben ser matizadas: los modelos entrenados muestran limitaciones para predecir con precisión los casos más extremos, es decir, aquellos radios con peor accesibilidad. Esta dificultad puede deberse, por un lado, a una subrepresentación de estos casos en el conjunto de entrenamiento —ya que funcionan como outliers— y, por otro, a la ausencia de variables que capten adecuadamente las condiciones que afectan a esos territorios. Entre las posibles mejoras, consideramos, en primer lugar, escalar la variable target en base logarítmica para obtener un rango más acotado sin distorsión de outliers; segundo, pensamos que puede ser útil incorporar predictores geográficos adicionales (estado de caminos, presencia y frecuencia de transporte público, barreras naturales como ríos o rutas

mal conectadas) que puedan reflejar con mayor fidelidad las restricciones concretas de accesibilidad: tercero, otra alternativa sería entrenar modelos diferenciados por región (por ejemplo, AMBA, NOA, Patagonia), permitiendo captar mejor las dinámicas locales y evitando la dilución de patrones en una lógica nacional agregada.

Estas estrategias no solo permitirían mejorar la capacidad predictiva del modelo en general, sino —sobre todo— afinar su desempeño en los territorios donde las condiciones de accesibilidad son más críticas. Al robustecer la capacidad explicativa del modelo en esos contextos, se avanza en una caracterización más precisa de las desigualdades territoriales en salud, que puede funcionar como insumo clave para la planificación de políticas públicas orientadas a reducir brechas estructurales.

7. Bibliografía


Vázquez Brust, A., Olego, T., & Rosati, G. (2018). *Construcción de un mapa de vulnerabilidad sanitaria en Argentina a partir de datos públicos*. Fundación Bunge y Born / IDAES-UNSAM.

World Health Organization. (2017). Health Systems Strengthening Glossary.


World Health Organization. (2021). Health Promotion Glossary of Terms.

8. Anexo 1


Mapas de aglomerados 10 a 18




Mapas aglomerados 19-27



Mapas aglomerados 28-36



Mapas aglomerados 37-42



Anexo 2.

